Занятие 1. Введение в таможенную статистику

Курс: Международные технологические рынки и технологическое лидерство

План занятия (80 мин)

1. **Теория** (25 мин): Таможенная статистика, ТН ВЭД, зеркальная статистика
2. **Структура проекта** (20 мин): Обзор проекта «Актуальная статистика внешней торговли»
3. **Практика** (30 мин): Первое знакомство с данными в Python
4. **Итоги** (5 мин)

Что такое таможенная статистика?

Определение: Систематизированные данные о внешней торговле страны, формируемые на основе таможенных деклараций.

Кто собирает:

- **ФТС России** — до января 2022 публиковала детальную статистику - **модель данных**
- **Национальные таможенные службы** — Китай, Индия, Турция и др.
- **UN Comtrade** — агрегированная международная база ООН

Основные показатели:

Показатель	Описание	Единица
STOIM	Статистическая стоимость	тыс. USD
NETTO	Вес нетто	кг
KOL	Количество в доп. единице	шт, л, $м^3$ и т.д.

Направления торговли (NAPR)

ИМ (**Импорт**) — товары, ввозимые в РФ

- С точки зрения РФ: что мы покупаем за рубежом
- Пример: китайский экспорт в РФ = российский импорт из Китая

ЭК (**Экспорт**) — товары, вывозимые из РФ

- С точки зрения РФ: что мы продаём за рубеж
- Пример: российский экспорт в Турцию = турецкий импорт из РФ

Важно: При работе с зеркальной статистикой направление «отзеркаливается» — экспорт партнёра становится нашим импортом.

Классификатор стран (`STRANA`)

Справочник: `metadata/STRANA.csv` — соответствие кодов стран и их названий.

Колонка	Описание
KOD	Двухбуквенный код ISO 3166-1 alpha-2 (CN, RU, US…)
NAME	Официальное наименование страны на русском

Объём: 254 записи (страны и территории). В данных ФТС используется код страны-партнёра по сделке.

Примеры кодов стран (из STRANA.csv)

Код	Страна
CN	КИТАЙ
RU	РОССИЯ
US	СОЕДИДИНЕННЫЕ ШТАТЫ
DE	ГЕРМАНИЯ
BY	БЕЛАРУСЬ
KZ	КАЗАХСТАН
TR	ТУРЦИЯ
IN	ИНДИЯ
KR	КОРЕЯ, РЕСПУБЛИКА
JP	ЯПОНИЯ
UA	УКРАИНА
GB	СОЕДИНЕННОЕ КОРОЛЕВСТВО

Специальные коды: EU — страны ЕС, NNN — неизвестная страна, AB/OS — Абхазия/Южная Осетия.

Использование: В торговых данных колонка STRANA содержит только код. Для получения названия — JOIN со справочником:

Что такое ТН ВЭД и зачем он нужен?

Определение: ТН ВЭД — классификатор товаров, используемый таможенными органами (ФТС России) для таможенных операций, применения пошлин и ведения статистики.

- **Фундамент:** В основе — Гармонизированная система (HS) Всемирной таможенной организации
- **Объём в проекте:** В `metadata/tnved.csv` — **31 532 записи** по 5 уровням вложенности
- **Принцип:** «От общего к частному» — с увеличением длины кода описание товара становится детальнее

Иерархическая структура кода (10 знаков)

5 уровней классификации в `metadata/tnved.csv`:

Знаков	Уровень	Пример	Роль
2	Группа	`01`	Материал/ отрасль (97 групп)
4	Товарная позиция	`0101`	Узкая категория (1 231 позиция)
6	Субпозиция	`010121`	Уровень HS, мировой стандарт (5 758)
8	Подсубпозиция	`01012100`	Уровень ЕАЭС (10 291)
10	Полный код	`0101210000`	Конкретный объект декларировани (14 155)

Распределение элементов по уровням (январь 2022)

Уровень	Кол-во элементов	Роль в классификации
2 (Группа)	97	Крупные разделы экономики
4 (Позиция)	1 231	Видовые категории товаров
6 (Субпозиция)	5 758	Мировой стандарт (HS)
8 (Подсубпозиция)	10 291	Региональная специфика (ЕАЭС)
10 (Товар)	14 155	Конкретный объект декларирования

Количество записей растёт к 10-му уровню — чем детальнее код, тем больше вариантов.

Пример 1: группа 01 (живые животные) — из tnved.csv

```
01      — ЖИВЫЕ ЖИВОТНЫЕ
0101    — ЛОШАДИ, ОСЛЫ, МУЛЫ И ЛОШАКИ ЖИВЫЕ
010121  — ЛОШАДИ ЖИВЫЕ: ЧИСТОПОРОДНЫЕ ПЛЕМЕННЫЕ
ЖИВОТНЫЕ
01012100 — (то же на уровне 8 знаков)
0101210000 — (полная детализация, 10 знаков)
010129  — ЛОШАДИ ПРОЧИЕ
010130  — ОСЛЫ, ЖИВЫЕ
0102    — КРУПНЫЙ РОГАТЫЙ СКОТ ЖИВОЙ
0103    — СВИНЬИ ЖИВЫЕ
```

Пример 2: группа 27 (топливо) — крупнейшая по обороту

Группа 27 объединяет минеральное топливо: уголь, нефть, нефтепродукты и **газы**. Иерархия строится по технологическим и химическим признакам (плотность, содержание серы, агрегатное состояние). Ниже — фрагмент дерева от группы до подсубпозиций.

Нефть и нефтепродукты (2710):

```
27      — ТОПЛИВО МИНЕРАЛЬНОЕ, НЕФТЬ И
ПРОДУКТЫ ИХ ПЕРЕГОНКИ; БИТУМИНОЗНЫЕ ВЕЩЕСТВА;
ВОСКИ МИНЕРАЛЬНЫЕ
2701    — УГОЛЬ КАМЕННЫЙ; БРИКЕТЫ, ОКАТЫШИ...
2709    — НЕФТЬ СЫРАЯ И НЕФТЕПРОДУКТЫ СЫРЫЕ
2710    — НЕФТЬ И НЕФТЕПРОДУКТЫ (кроме сырых)
271012  — ЛЕГКИЕ ДИСТИЛЛЯТЫ (бензины)
27101241 — БЕНЗИНЫ МОТОРНЫЕ (с октановым
числом < 95)
2710124110 — БЕНЗИН АВТОМОБИЛЬНЫЙ (октановое
число < 80)
271019  — ПРОЧИЕ ДИСТИЛЛЯТЫ (дизель, керосин,
мазут)
```

Природный газ — трубопроводный и СПГ (2711):

В группе **2711** учитываются углеводородные газы. Ключевое различие для аналитики — **способ доставки**: по трубам (газообразное состояние) или в сжиженном виде танкерами (СПГ).

Код (пример)	Наименование	Пояснение
2711	Газы нефтяные и углеводородные газообразные	Вся позиция: природный газ, пропан, бутан и др.
2711 11	Природный газ сжиженный	**СПГ (LNG)** — доставка танкерами, регазификация у потребителя
2711 21	Природный газ в газообразном состоянии	**Трубопроводный газ** — поставки по магистральным газопроводам

Для России и партнёров разделение 2711 11 (СПГ) и 2711 21 (труба) критично: география, цены и контракты сильно различаются. В зеркальной статистике партнёра код может быть тем же (HS/CN), но единицы измерения и агрегация иногда отличаются от российской практики.

Пример 3: группы 84, 85, 87 — машины и оборудование

```
84      — РЕАКТОРЫ ЯДЕРНЫЕ, КОТЛЫ, ОБОРУДОВАНИЕ
И МЕХАНИЧЕСКИЕ УСТРОЙСТВА; ИХ ЧАСТИ
85      — ЭЛЕКТРИЧЕСКИЕ МАШИНЫ И ОБОРУДОВАНИЕ;
ЗВУКОЗАПИСЫВАЮЩАЯ АППАРАТУРА...
87      — СРЕДСТВА НАЗЕМНОГО ТРАНСПОРТА (кроме
ж/д)
```

Эти три группы — среди топ-5 по обороту в данных ФТС 2021–2022.

Пример 4: Эволюция кода — смартфоны

Проследим путь классификации одного из самых популярных товаров:

```
85          — Электрические машины и
оборудование... (Группа)
8517        — Аппараты телефонные, включая
смартфоны... (Позиция)
851713      — Смартфоны (Субпозиция — введена в
2022 году)
85171300    — Смартфоны (Подсубпозиция)
8517130000  — Смартфоны (Полный 10-значный код
ТН ВЭД)
```

Префикс «ШТ-» в названии — указание на основную единицу измерения (штуки).

Пример 5: Эволюция кода — легковые автомобили

Транспортные средства (группа **87**) — ещё один крупный блок по обороту. Легковые авто — позиция **8703**; детализация идёт по типу двигателя и объёму:

```
87            — СРЕДСТВА НАЗЕМНОГО ТРАНСПОРТА
(кроме ж/д)
8703          — АВТОМОБИЛИ ЛЕГКОВЫЕ И ПРОЧИЕ
ТРАНСПОРТНЫЕ СРЕДСТВА ДЛЯ ПЕРЕВОЗКИ ЛЮДЕЙ
870321        — с двигателем с искровым
зажиганием, объёмом цилиндров ≤ 1000 см³
870322        — объёмом цилиндров > 1000 см³,
но ≤ 1500 см³
870323        — объёмом цилиндров > 1500 см³,
но ≤ 3000 см³
870324        — объёмом цилиндров > 3000 см³
8703234190    — пример подсубпозиции (легковые,
1500–3000 см³, прочие)
```

На уровне 6 знаков уже видна ключевая для статистики и пошлин характеристика — объём двигателя; дальше различают тип кузова, экологический класс и т.д.

Технические особенности данных tnved.csv

Для аналитики важно понимать структуру файла:

Колонка	Описание
KOD	Текстовое поле — сохранять ведущие нули (`01`, а не `1`)
NAME	Официальное наименование; может содержать единицы измерения (ШТ-, 1000 Л-), технические пояснения
level	Индикатор вложенности (2, 4, 6, 8, 10) — упрощает построение древовидных моделей в Excel, Python, Power BI

Особенности кодирования

- **Дополнение нулями справа:** `2710` → `2710000000` (до 10 знаков)
- **Иерархия:** каждый уровень — префикс следующего: `27` → `2701` → `271012` → `27101241` → `2710124110`

Зеркальная статистика

Определение: Данные о торговле с РФ, собранные **страной-партнёром** (а не российской таможней).
Почему важна:

- С января 2022 официальная статистика ФТС недоступна
- Зеркальная статистика — единственный легальный источник актуальных данных
- Данные партнёров часто публикуются быстрее, чем UN Comtrade

Источники в проекте:

- Китай (customs.gov.cn)
- Индия (commerce.gov.in)
- Турция (trademap)
- UN Comtrade (для стран без национальных данных)

Почему прямая и зеркальная статистика отличаются?

1. **CIF vs FOB:** Импорт учитывается по CIF (стоимость + страхование + фрахт), экспорт — по FOB (франко-борт)
2. **Страна происхождения vs страна отправления:** Транзитные операции
3. **Временной лаг:** Морские перевозки — товар в пути
4. **Разная классификация:** Один товар — разные коды ТН ВЭД в разных странах

Идея и структура проекта

Идея: Собрать **data-product** по внешней торговле России на основе **зеркальной статистики** партнёров. После закрытия данных ФТС это единственный легальный способ получить актуальную картину экспорта и импорта. Задача — не просто хранить сырые выгрузки, а вести единый пайплайн: сбор с сайтов таможен/статслужб → очистка и приведение к общим кодам (страны, ТН ВЭД) → хранение в одной БД → аналитика и дашборды.

Фокус MVP: Китай, Индия, Турция — ключевые партнёры; исторические CSV ФТС (2021–нач. 2022) используются как референс и для сопоставления с зеркальными данными.

Целевая аудитория: участники ВЭД, логистика, инвестиционная аналитика; плюс учебные материалы для МГИМО.

Структура репозитория (https://github.com/quantviews/mgimo-foreign-trade):

```
mgimo-foreign_trade/

├── data_processed/     # Сводные Parquet
(fts_2021_2022.parquet и др.)
├── src/load_fts_csv.py # Объединение CSV ФТС в
сводный датасет
├── src/collectors/     # Сборщики зеркальной
статистики
```

```
├── docs/                    # документация
├── db/                      #
unified_trade_data.duckdb (после merge.py)
├── metadata/                # Справочники (страны,
ТН ВЭД)
```

Модель данных (схема)

Колонка	Тип	Описание
NAPR	VARCHAR	ИМ / ЭК
PERIOD	DATE	Отчётный период (YYYY-MM-DD)
STRANA	VARCHAR	ISO2 код страны (CN, TR, IN)
TNVED	VARCHAR	Код ТН ВЭД (8–10 знаков)
STOIM	DECIMAL	Стоимость, тыс. USD
NETTO	DECIMAL	Вес нетто, кг
KOL	DECIMAL	Количество в доп. единице
EDIZM	VARCHAR	Единица измерения
TNVED2, TNVED4, TNVED6	VARCHAR	Агрегированные коды

Дополнительные единицы измерения (EDIZM)

Справочник: `metadata/edizm.csv` — стандартизированные единицы для колонки KOL.

KOD	NAME
166	КИЛОГРАММ
168	ТОННА (1000 КГ)
796	ШТУКА
798	ТЫСЯЧА ШТУК
112	ЛИТР
130	1000 ЛИТРОВ
113	КУБИЧЕСКИЙ МЕТР
006	МЕТР
055	КВАДРАТНЫЙ МЕТР
246	1000 КИЛОВАТТ-ЧАС
323	БЕККЕРЕЛЬ

Роль: KOL — количество в единице EDIZM. NETTO — всегда вес в кг. Для товаров «в штуках» KOL даёт натуральный объём, для «в литрах» — объём и т.д.

Натуральные показатели

Помимо стоимости (STOIM) таможенная статистика содержит **физические объёмы**:

Показатель	Единица	Описание
NETTO	кг	Вес нетто — есть почти у всех товаров
KOL	зависит от EDIZM	Количество в дополнительной единице (штуки, литры, м^2, кВт·ч…)

Зачем нужны: Отделение ценовых эффектов от реальных объёмов. Рост стоимости может быть из-за роста цен или роста поставок — только натуральные показатели показывают реальные потоки.

Эффективные цены по категориям

Эффективная цена — стоимость за единицу физического объёма:

- **Для весовых товаров** (NETTO > 0):
  `цена за кг = STOIM / NETTO`
  (STOIM в тыс. USD → результат в тыс. USD/кг)
- **Для штучных/объёмных** (KOL > 0, EDIZM = **ШТУКА и т.д.**):
  `цена за единицу = STOIM / KOL`
  (при KOL в тыс. шт. — цена за тыс. шт.)

  Важно: Сравнивать цены только внутри одной товарной категории (одинаковый TNVED) и одной единицы измерения. Суммарные цены по группе: `SUM(STOIM) / SUM(NETTO)` или `SUM(STOIM) / SUM(KOL)`.

Прямые данные ФТС

Источник: `data_raw/fts_data/` — CSV-файлы по месяцам (янв 2021 — янв 2022).
Это **прямая статистика** российской таможни до её закрытия. Идеальная точка старта для понимания структуры данных.

Практика 2: Загрузка и просмотр данных ФТС

```
import pandas as pd
from pathlib import Path

# Путь к сводному файлу (запускать из корня пр
parquet_path = ROOT / "data_interim_csv" / "ft
df = pd.read_parquet(parquet_path)

print(f"Загружено строк: {len(df):,}")
print(f"Колонки: {df.columns.tolist()}")
print(df.head(10))
```

```
Загружено строк: 1,907,996
Колонки: ['NAPR', 'STRANA', 'TNVED', 'STOIM',
'NETTO', 'KOL', 'EDIZM', 'PERIOD', 'TNVED2',
'TNVED4', 'TNVED6']
  NAPR STRANA       TNVED         STOIM
NETTO       KOL EDIZM  \
0   ЭК     KZ  9504500002  3.833371e+04
2.353130e+02     495.0   796
1   ИМ     BY  9403903000  1.526542e+06
1.045093e+06      27.0  None
2   ЭК     BY  9603901000  2.775500e+02
8.045400e+01     261.0   796
3   ЭК     PL              1.931287e+08
```

Практика 3: Изучение структуры

```
# Базовая информация
df.info()

# Описательная статистика
df[['STOIM', 'NETTO', 'KOL']].describe() # не

# Направления и страны
print("Направления:", df['NAPR'].unique())
print("Страны (топ-10):", df['STRANA'].value_c
print("Период:", df['PERIOD'].min(), "–", df['
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1907996 entries, 0 to 1907995
Data columns (total 11 columns):
 #   Column  Dtype
---  ------  -----
 0   NAPR    object
 1   STRANA  object
 2   TNVED   object
 3   STOIM   float64
 4   NETTO   float64
 5   KOL     float64
 6   EDIZM   object
 7   PERIOD  datetime64[ns]
```

Практика 4: Простые агрегации (pandas)

Задание 1: Сколько записей по каждой стране?

```
by_country = df.groupby('STRANA').size().sort_
print(by_country.head(15))
```

```
STRANA
BY    148679
KZ    104104
UA     78555
CN     75908
DE     74997
IT     56932
US     52313
PL     51539
AM     48868
FR     44808
KG     41516
TR     40623
```

Задание 2: Сумма импорта и экспорта по странам за весь период

```
import_by_country = df[df['NAPR'] == 'ИМ'].gro
export_by_country = df[df['NAPR'] == 'ЭК'].gro
```

```
print("Импорт (топ-10):"); print(import_by_cou
print("\nЭкспорт (топ-10):"); print(export_by_
```

```
Импорт (топ-10):
STRANA
CN    7.987319e+10
DE    2.893200e+10
US    1.836689e+10
BY    1.650556e+10
KR    1.440661e+10
FR    1.287088e+10
IT    1.278864e+10
JP    9.896967e+09
KZ    7.680481e+09
TR    7.129686e+09
Name: STOIM, dtype: float64
```

Практика 5: Топ товарных групп (TNVED2)

```
top_tnved2 = df.groupby('TNVED2').agg(
    total_stoim=('STOIM', 'sum'),
    cnt=('TNVED', 'count')
).sort_values('total_stoim', ascending=False).
print(top_tnved2)
```

```
         total_stoim     cnt
TNVED2
27      2.336339e+11   20153
        9.903426e+10    1883
84      6.988843e+10  232204
85      4.626939e+10  194388
72      3.763019e+10   37634
71      3.431987e+10    6625
87      3.274077e+10   47071
39      2.033164e+10   83405
30      1.733966e+10   16838
31      1.420929e+10    6283
44      1.339258e+10   30379
```

Практика 6: Единицы измерения и эффективные цены

Задание 1: Какие единицы измерения (EDIZM) чаще всего встречаются в данных?

```
print(df['EDIZM'].value_counts().head(15))
```

```
EDIZM
796    535920
055     49612
715     27488
113     14285
112     14166
831      4485
163      3518
861      2309
798      2059
845      1272
852       989
162       899
```

Задание 2: Рассчитать среднюю эффективную цену (тыс. USD за тонну) по товарным группам TNVED2 для импорта. Использовать только строки, где NETTO > 0.

```
imp = df[(df['NAPR'] == 'ИМ') & (df['NETTO'] >
price_by_tnved2 = imp.groupby('TNVED2').agg(
```

```
    total_stoim=('STOIM', 'sum'),
    total_netto=('NETTO', 'sum')
)
price_by_tnved2['price_per_tonne'] = price_by_
print(price_by_tnved2.sort_values('total_stoim
```

```
         total_stoim   total_netto
price_per_tonne
TNVED2
84      5.853611e+10  4.866623e+09
12028.076734
85      3.982898e+10  1.983995e+09
20075.145561
87      2.882560e+10  3.462183e+09
8325.845516
        1.509862e+10  1.478218e+09
10214.066072
30      1.472786e+10  1.759806e+08
83690.250251
```

Задание 3: Сравнить эффективные цены импорта из Китая и Германии по группе **2710** (нефтепродукты: бензин, дизель, мазут) за 2021 год. Группа более гомогенна, чем машины.

```
g2710 = df[(df['NAPR'] == 'ИМ') & (df['TNVED4'
            & (df['PERIOD'].dt.year == 2021) &
by_country = g2710.groupby('STRANA').agg(total
```

```
by_country['price_per_tonne'] = by_country['to
print(by_country)
```

```
         total_stoim   total_netto
price_per_tonne
STRANA
CN      1.588514e+06  5.628781e+05
2822.127250
DE      1.311451e+08  3.980568e+07
3294.633576
```

Прямая и зеркальная статистика: группа 27 (топливо)

В проекте для группы **27** (минеральное топливо, нефть, газ) доступны два набора данных:

Файл	Опи
`data_interim_csv/fts_2021_2022_TNVED2_27.parquet`	**Пря дан ФТС** рос там стат по к
`data_interim_csv/CN_TNVED2_27.csv`	**Зер ста КНР** дан там Кит код (тор Кит Рос

Зачем два источника: Прямая статистика ФТС после января 2022 года недоступна. Зеркальная (данные партнёра) даёт возможность анализировать **текущие** годы. Пересечение по **2021 году** позволяет

сопоставить прямую и зеркальную статистику и оценить расхождения (CIF/FOB, классификация, лаги).
Направления: В зеркальной статистике КНР направление уже задано с точки зрения партнёра: `NAPR=ИМ` — импорт Китая из РФ, `NAPR=ЭК` — экспорт Китая в РФ; менять кодировку не нужно. При сопоставлении с ФТС: российский экспорт в Китай = ФТС `NAPR=ЭК`, `STRANA=CN` = в данных КНР `NAPR=ИМ`; российский импорт из Китая = ФТС `NAPR=ИМ`, `STRANA=CN` = в данных КНР `NAPR=ЭК`.

Первичный анализ: сырая нефть (2709)

Берём только **сырую нефть** (код 2709). Строим помесячную динамику экспорта РФ в КНР в **физических единицах** (вес нетто, столбец NETTO, кг) — так сопоставление источников не зависит от цен и валюты. В 2021 **году** — оба источника, с 2022 **года** — только зеркальная статистика КНР.

По оси ординат — **тыс. т** (сумма NETTO по месяцам, пересчитанная из кг). Сравнение по весу не зависит от курса и цен; при наличии данных КНР две линии в 2021 году показывают расхождение учёта по объёму.

Итоги занятия 1

- **Таможенная статистика** — данные о внешней торговле на основе таможенных деклараций
- **Классификаторы** — STRANA (страны), TNVED (товары), EDIZM (единицы измерения)
- **Натуральные показатели** — NETTO (кг), KOL (в единицах EDIZM)
- **Эффективная цена** — STOIM/NETTO или STOIM/KOL для анализа цен по категориям
- **Прямая и зеркальная статистика** — ФТС (2021–нач. 2022) и данные партнёров (КНР и др.) для текущих лет; пересечение по 2021 году даёт возможность валидации
- **Практика** — сводный датасет ФТС, агрегации, расчёт цен, сравнение ФТС и КНР по группе 27

Домашнее задание

1. **Документация:** Изучить `https://github.com/quantviews/mgimo-foreign-trade/blob/main/docs/data_model.md`, `https://github.com/quantviews/mgimo-foreign-trade/blob/main/docs/fts_csv_format.md`.
2. **Агрегации по сводному ФТС:** Топ-5 стран по импорту за 2021 год. Выполнить Практику 6: эффективные цены по группе 27 для импорта из трёх стран-партнёров.
3. **Сравнение прямой и зеркальной статистики (группа 27):**

- Загрузить `fts_2021_2022_TNVED2_27.parquet` и `CN_TNVED2_27.csv`.
- Построить по годам (2019–2025) динамику стоимости по зеркальной статистике КНР: импорт Китая из России и экспорт Китая в Россию (тыс. USD).
- За 2021 год: сравнить с агрегатами ФТС (экспорт РФ в КНР и импорт РФ из КНР). Рассчитать средние цены ($/т, или $/баррель) и относительное расхождение (в %) и кратко предложить возможные причины (FOB/CIF, классификация, лаг).

4. **Отчёт:** Оформить результат в виде короткого отчёта (1–2 страницы): таблица или график динамики, таблица сравнения за 2021, выводы.

Дополнительно: Найти в `metadata/tnved.csv` самый длинный текст описания товара (колонка NAME). В группах 84 или 85 описания часто занимают несколько строк — это иллюстрирует сложность таможенного администрирования.

Speaker notes